

“金织万象，智投千面” ——FIN-R1 赋能的自适应量化投资引擎

摘要

全球经济进入结构性调整阶段，金融市场波动性显著上升，传统投资模式面临信息过载、行为偏差与高门槛三大困境。在此背景下，融合人工智能的智能量化投资成为突破瓶颈的关键路径。

本文提出 FinLoom 自适应量化投资引擎，以 FIN-R1 金融大语言模型为核心，构建“看得懂、投得起、守得住、学得快”的核心能力体系。系统采用自下而上的五层智能架构，实现从数据治理、策略生成、交易执行到智能风控的端到端闭环。通过多模态语义理解，系统可解析非结构化信息并生成投资决策；借助高速执行引擎保障交易效率；依托动态风控机制控制极端回撤；结合持续学习框架实现策略进化。同时，系统通过自然语言交互与用户画像，为不同风险偏好与资金规模的投资者提供个性化服务，推动机构级量化能力向大众普惠。

实证研究表明，在 2015 - 2024 年中国 A 股市场环境下，FinLoom 智能策略在短期、中期与长期投资周期中均显著优于移动平均线、RSI、布林带等传统技术策略，收益更高、回撤更小、风险调整后收益更优。该系统不仅验证了 AI 驱动量化投资的有效性，也为金融服务的智能化与普惠化提供了可行的技术范式。

关键词：金融大语言模型；智能量化投资；个性化资产配置；普惠金融

目录

一、 背景分析	1
(一) 经济波动与量化发展	1
(二) 财富需求与困境突破	2
(三) 监管优化与制度创新	4
(四) 技术发展历程	6
二、 智能系统设计	7
(一) 核心架构	7
(二) 创新亮点	22
(三) 用户群体分析	23
三、 实证对比分析	25
(一) 收益率表现对比	25
(二) 技术原理分析	28
(三) 传统策略在不同投资周期下均面临结构性缺陷	28
四、 结论	29

图目录

图 1	2019-2024 年全球 GDP 增长率变化图	1
图 2	市场综合拥挤度指标走势（2020-2024）	2
图 3	中国家庭金融资产占比变化趋势（2019-2024）	2
图 4	年度最大回撤与 10 年平均水平（2010-2024）	3
图 5	学术发展历程	6
图 6	产品模块流程图	8
图 7	“看得懂” - FIN-R1 多模态决策引擎核心逻辑代码	9
图 8	“投得快” - 高速执行引擎核心逻辑代码	12
图 9	“守得住” - 智能风控系统核心逻辑代码	13
图 10	APP 端客户投资组合展示界面	16
图 11	“学得快” - 持续学习系统核心逻辑代码	19
图 12	APP 功能页面展现	21
图 13	FinLoom 产品代码仓库图	22
图 14	各投资者基本信息与主要痛点	24
图 15	2015-2024 年策略累计收益率曲线对比	25
图 16	长期收益与持续风险调整表现	27
图 17	策略综合性能雷达图	28
图 18	不同市场环境下策略表现箱线图	29

表目录

表 1 中国量化投资“普惠门槛”断层示意图 3

表 2 国际人工智能监管政策发展时间表（2023-2025） 4

表 3 中国证券市场重要政策法规发展时间轴（2020-2024） 5

表 4 各地方最新政策文件 5

表 5 短期投资策略表现对比 26

表 6 中期投资策略表现对比 26

表 7 长期投资策略表现对比 27

“金织万象，智投千面” ——FIN-R1 赋能的自适应量化投资引擎

一、背景分析

当前，全球金融体系正处于深刻的**结构性调整阶段**。世界经济从 2020 年的深度衰退中走来，其增长动能与市场生态均发生显著变化。在此背景下，传统投资方式面临着前所未有的变革困境，亟待新的投资模式的突现。

（一）经济波动与量化发展

据世界银行《全球经济展望》（2024 年 6 月）报告，2020 年全球实际 GDP 增速因疫情冲击降至-3.1%，随后于 2021 年回升至 6.0%。尽管此后经济逐步复苏，但近三年增速持续徘徊于 2%-3% 区间，表明全球经济已进入低增长、高波动的新常态。

2019-2024 年全球 GDP 增长率变化图




图 1 2019-2024 年全球 GDP 增长率变化图

这种调整并非简单的周期性回落，而是全球经济增长动能的根本性转换。金融市场的波动性显著上升，传统的投资驱动和出口导向增长模式正逐步让位于以科技创新和数字经济为核心的新增长范式，投资市场迎来了历史新机遇。

随着资产证券化与私募基金等的大力发展，**量化投资**已成为全球资本市场的主导力量。截至 2024 年底，全球量化基金管理资产规模突破 1.5 万亿美元，年均复合增长率超过 15%。中国量化投资市场虽起步较晚，但增长势头强劲，量化私募基金管理规模已超过 2 万亿元人民币，在价格发现、流动性提供等方面发挥着日益重要的作用。这一结构性转变，为智能投资系统的规模化应用提供了坚实基础。从微观层面看，**市场综合拥挤度指标**从 2020 年的 0.46 攀升至 2024 年的 0.78（图 3），传统策略同质化严重，依赖人工经验的模式难以持续创造超额收益，亟需通过技术创新构建差异化竞争优势。




图 2 市场综合拥挤度指标走势 (2020-2024)

(二) 财富需求与困境突破

随着资本市场的扩张式发展，家庭财富配置正经历结构性转型，居民理财意识进一步提高，财富管理需求相应升级，但传统投资模式的瓶颈也亟待突破。




图 3 中国家庭金融资产占比变化趋势 (2019-2024)

中国人民银行调查数据显示（图 4），金融资产在家庭总资产中的占比从 2019 年的 35.3% 上升至 2024 年的 42.1%，五年增长率达 19.3 个百分点。居民理财意识觉醒，对专业、高效、普惠的投资服务需求持续升级。同时，机构投资者的崛起进一步推动了市场的专业化进程，养老基金、保险资金、银行理财子公司等长期资金的加速配置，对投资决策的科学性、稳定性和可追溯性提出了更高要求。

然而，现有传统投资模式存在三大困境——信息过载（决策效率低）、行为偏差（决策质量差）、高门槛（服务成本高），亟需通过技术架构革新来突破瓶颈。

现代金融市场的**信息密度**已远超人类认知极限。中国 A 股市场每日产生的结构化数据超过 10TB，非结构化信息达 50 万条，且日内振幅超过 2% 的交易日占比从 2019 年的 28.3% 上升至 2024 年的 41.7%。传统的人工分析方法在处理如此海量、高频的信息流时显得力不从心。投资决策的时效性严重滞后，经典动量与价值因子的生命周期从 18 个月压缩至不足 6 个月，人工调参节奏远远落后于市场变化速度。这种信息处理能力与市场变化速度之间的巨大鸿沟，成为制约传统投资模式发展的核心瓶颈。




图 4 年度最大回撤与 10 年平均水平（2010-2024）

行为金融学研究充分证明了**人类投资者的系统性偏差**。在市场剧烈波动期间，恐惧与贪婪等情绪因素的影响更为显著，“追涨杀跌”的非理性行为普遍存在。如图 5 可见，传统“买入并持有”策略的年化最大回撤从 2010-2019 年的-11%扩大至当前的-18%，波动加剧背景下人工决策的脆弱性进一步凸显。这类由人性弱点引发的非理性行为不仅直接侵蚀投资者收益，也在一定程度上加剧了市场的顺周期波动与极端风险积聚。

表 1 中国量化投资“普惠门槛”断层示意图

服务类型	最低门槛（万元）	管理费（%）	业绩提成（%）	服务人群覆盖率（%）
私募基金	100	2.0	20	5
传统财富管理	50	1.5	15	15
银行理财	1	0.8	0	60
AI 智能投顾	0.1	0.3	0	95
传统量化基金	10	1.2	10	25

中国量化投资“普惠门槛”断层限制长尾资金发展。如表 1 所示，在当前的中国市场，投资领域门槛依旧居高不下，传统的量化投资需要投资者具备深厚的数统能力、计算机编程以及金融理论背景。这对于大部分普通投资者来说几乎是不可能完成的任务。中国人民银行《2023 普惠金融指标分析报告》显示，全国约 4.8 亿农村居民与 1.2 亿城市低收入群体年化理财收益低于 2%，而私募量化产品 100 万元起投、1.5%管理费及后

端分成的成本结构将长尾资金挡在门外。即使是专业投资者，也需要投入大量时间和精力来学习、开发和维护复杂的投资模型，这大大限制了量化投资技术的普及和应用。

（三）监管优化与制度创新

全球主要经济体在**人工智能金融应用监管**方面呈现协同演进态势。

表 2 国际人工智能监管政策发展时间表（2023-2025）

出台时间	政策文件	重点内容
2023 年 7 月	美国《SEC 算法交易监管提案》	算法透明度要求，利益冲突披露义务，投资者保护措施强化。
2024 年 3 月	英国《AI 监管原则框架》	比例监管原则，创新沙盒机制扩展，跨部门协调机制建立。
2025 年 1 月	美国《SEC 监管政策调整》	放松 AI 量化策略限制，创新与监管平衡，为 AI 发展创造宽松环境。
2025 年 4 月	英国《FCA-NVIDIA 超级沙盒计划》	GPU 加速测试环境，真实市场数据接入，监管豁免试点机制。
2025 年六月	欧盟《AI 法案》正式实施	金融 AI 系统合规要求明确，算法审计制度建立，跨境数据流动规范。

如表 2 所示，美国监管当局首先完成了从技术中性到专门指导的政策转向，商品期货交易委员会（CFTC）于 2024 年 12 月正式发布 AI 使用工作指导意见，为 AI 驱动的量化策略发展创造了宽松环境。欧盟随之通过 AI 法案和数字运营韧性法案（DORA）的协调实施，建立了系统化的监管框架。英国金融行为监管局（FCA）也相应采取了原则导向的创新支持新模式，并于 2025 年 4 月与 NVIDIA 合作推出“超级沙盒”，为 AI 投资策略提供理想测试环境。

从 2020 年的观望期，到 2023-2024 年的积极介入期，再到 2025 年的平衡发展期，国际监管政策的演变为量化投资行业提供了日益清晰的发展路径。监管确定性的增强有利于长期投资，沙盒和测试环境支持创新，国际标准的趋同降低了合规成本。

“法与时转则治，治与世齐则有功。”法律不是刻在石板上的教条，治理也不能用“老药方”，近年来，国家与时俱进，不仅相关单位大力出台相关政策，监管方面也逐步推进由他审到自审的稳步转变。

在顶层设计的系统化布局方面，中国在人工智能金融应用方面形成了从国家到地方的完整政策体系。在国家层面，如表 3 所示，《证券法》的全面修订标志着证券市场基础法律制度的现代化，而《证券市场程序化交易管理规定》的正式实施则为该市场提供了更加清晰和完善的法律框架。与此同时，科创板和创业板注册制改革的稳步推进，不仅扩大了可投资标的范围，也为量化策略的实施提供了更加市场化的制度环境。

表 3 中国证券市场重要政策法规发展时间轴（2020-2024）

出台时间	政策文件	重点内容
2020 年 3 月 1 日	《中华人民共和国证券法》 （2019 年修订版）	<ul style="list-style-type: none">全面推行证券发行注册制，取消发行审核委员会制度大幅提高证券违法违规成本，最高处罚金额提升至 2000 万元完善投资者保护制度，建立证券代表人诉讼制度
2020 年 6 月 12 日	《创业板首次公开发行股票注册管理办法（试行）》	<ul style="list-style-type: none">创业板正式实施注册制改革，审核权限移交深交所建立更加包容的上市标准，支持创新创业企业优化发行承销机制，提高定价市场化水平
2024 年 4 月 12 日	《国务院关于加强监管防范风险推动资本市场高质量发展的若干意见》（新"国九条"）	<ul style="list-style-type: none">明确要求加强对高频量化交易监管出台程序化交易监管规定，规范量化投资发展强化市场风险综合研判，增强市场内在稳定性
2024 年 6 月 19 日	《证券市场程序化交易管理规定（试行）》	<ul style="list-style-type: none">系统规范程序化交易行为，明确监管要求建立程序化交易投资者分类管理制度加强行情授权管理，健全差异化收费机制

在地方层面，地方政府响应国家层面号召，积极落实并推进相关专项差异化的产业扶持政策，并出资出力，辅助相关产业良序发展，其中，北京发布《推动数字金融高质量发展的意见》，支持金融机构运用 AI 技术优化服务。广东省在金融等领域拓展 AI 应用场景，提供资金和政策支持。数字人民币试点从最初的“10+1”扩展到 17 个省市的 26 个地区，为智能投资系统的支付结算创新提供了基础设施支持。这种多层次、全方位的政策支持体系为智能投资系统的发展营造了良好的制度环境。

表 4 各地方最新政策文件

发布时间	政策文件	重点内容
2023 年 2 月 4 日	《深圳市金融科技专项发展规划（2023-2025 年）》	目标培育 10 家以上国际知名金融科技领军企业
2024 年 10 月 17 日	《北京市推动数字金融高质量发展的意见》	支持金融机构运用 AI 技术优化服务，从加大核心要素供给、激发数字金融发展动能等四方面提出 15 项措施
2025 年 3 月 10 日	《广东省推动人工智能与机器人产业创新发展若干政策措施》	在金融等领域拓展 AI 应用场景，提供资金和政策支持
2025 年 5 月 20 日	《关于支持人工智能创新发展的若干措施》	提出打造 100 亿元以上人工智能基金群，金融领域标杆项目最高补助 500 万元

综观全球经济格局重塑、传统模式困境凸显、政策环境持续优化三大趋势，智能投资系统的发展已具备天时地利人和的历史性条件。全球量化投资市场的快速扩张提供了广阔的应用空间，传统投资模式的内在缺陷创造了迫切的变革需求，各国监管政策的协调演进构建了良好的制度环境，以 FIN-R1 为代表的技术突破奠定了坚实的创新基础。

智能投资系统不仅是技术进步的产物，更是金融民主化和普惠化的重要载体。通过降低投资门槛、提高决策效率、优化资源配置，智能投资系统正在重塑金融投资的基本范式。

（四）技术发展历程

量化投资在金融市场中扮演着日益重要的角色，其演进历程呈现出清晰的技术发展路径：从传统统计模型到机器学习方法，再至当前以大语言模型（Large Language Models, LLMs）为代表的人工智能技术。近年来，LLM 在量化投资中的应用已逐步从初步探索迈向系统化研究，形成了较为完善的理论体系并积累了丰富的实证证据。本文基于国内外权威期刊与前沿研究成果，系统梳理 LLM 在量化投资中的学术演进脉络、核心理论贡献以及当前面临的主要挑战。

从 FinBERT 破冰到 BloombergGPT 崛起，再到多代理智能体落地，金融大模型三年三级跳：先让文本会“说话”，再让领域会“思考”，如今更让数据、因子、决策全流程会“协作”，一条由 NLP 到 AGI 式投资助手的演进轨迹已清晰可见。

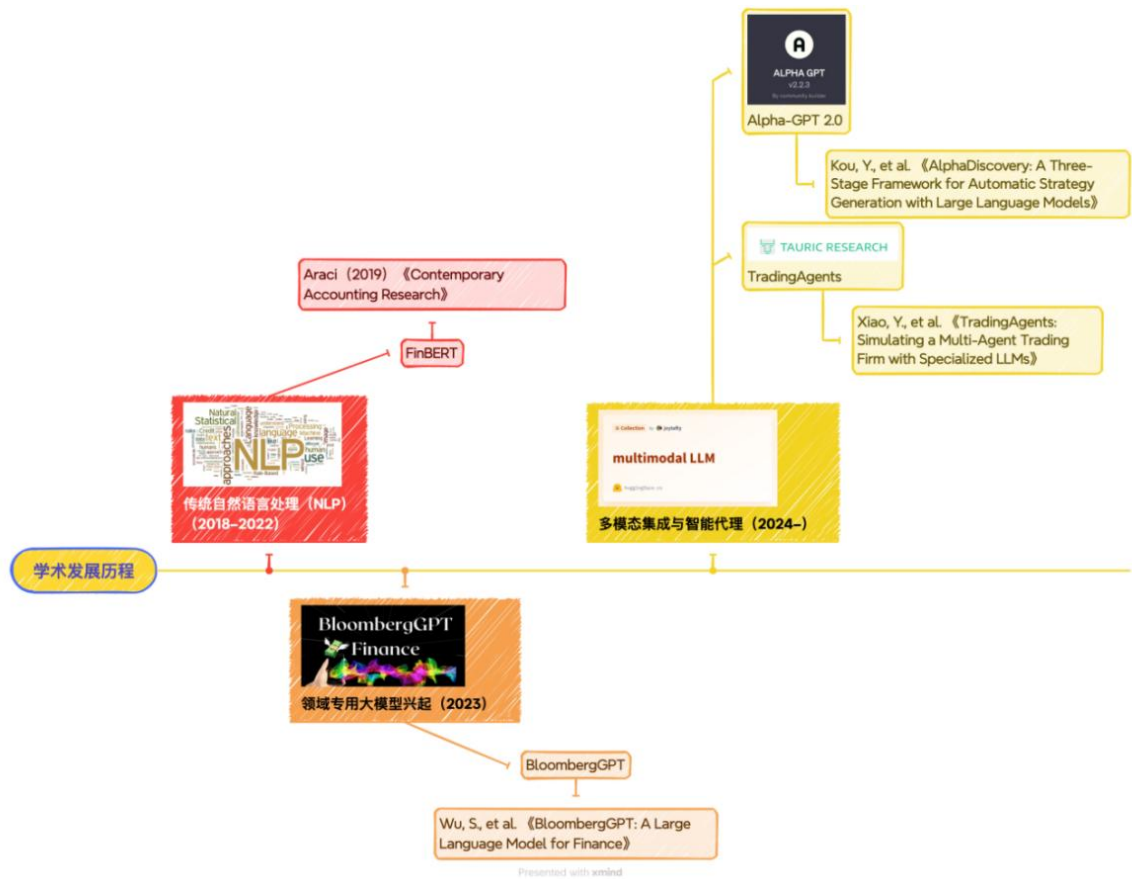


图 5 学术发展历程

1. NLP 初步应用阶段

早期研究主要集中于将传统自然语言处理（NLP）技术应用于金融文本分析，核心突破在于解决通用模型在金融领域的适配性问题。基于 Vaswani 等人（2017）提出的 Transformer 架构文献，学界普遍认为该框架的语境建模能力远超传统 Word2Vec 等方法，为金融文本的深度解析提供了技术基础。该阶段的重要成果包括基于 BERT 架构

的金融领域预训练模型，例如，Araci（2019）在《Contemporary Accounting Research》上提出的 FinBERT，成为金融领域专用语言模型的先驱。基于 A 股业绩说明会文本分析的文献验证，相较于通用模型，FinBERT 生成的上下文敏感情感指标能更有效区分未来的赢家与输家，尤其在小盘股中表现突出，其在情感分析任务中的准确率从通用模型的 62.1% 提升至 88.2%，充分证明了领域专用预训练的价值。

同一时期，传统机器学习方法在量化投资中的应用也为后续 LLM 研究奠定了方法论基础。Gu, Kelly 和 Xiu（2020）发表于《Review of Financial Studies》的论文“Empirical Asset Pricing via Machine Learning”，系统比较了多种机器学习模型在资产定价中的表现。该研究不仅荣获 2018 年 Swiss Finance Institute 杰出论文奖，更关键的是建立了机器学习在金融应用中可复现的评估框架，为后来 LLM 研究的实证设计提供了重要参考。

2. 专用模型的兴起阶段

2023 年成为金融 LLM 发展的关键节点，核心进展聚焦于领域专用模型的构建与评估体系的完善。基于 Fazlija 和 Harder（2022）关于金融新闻情感分析的研究文献，学界已明确通用 LLM 在金融专业术语理解、市场事件关联等任务中存在显著局限，亟需针对性训练优化。在此背景下，Bloomberg 推出的 BloombergGPT 标志着该领域的一项重大突破。Wu 等人（2023）在 arXiv 上发表的研究构建了首个专为金融领域训练的 500 亿参数模型，使用超过 3630 亿个金融相关 token 进行训练。基于 FinCUGE 与 FinEval 等基准的测试文献显示，该模型在金融新闻分类、舆情分析等任务中，精度与召回率均显著优于通用大模型，有力论证了领域专用训练的有效性。

与此同时，评估基准的构建也成为该阶段的重要议题。Xie 等人（2023）提出的 PIXIU 基准，涵盖 15 个不同的金融数据集，覆盖情感分析、事件提取等多类任务为该领域提供了标准化评估框架，推动了研究的规范化和可比性。

3. 多模态集成阶段

最近的研究呈现出两个显著趋势：多模态数据融合与智能代理系统的构建。这反映出学界对 LLM 在投资中角色的理解正从辅助文本处理工具转向综合决策支持系统。

Fatouros 等人（2024）开发的 MarketSenseAI 系统是该方向的代表性工作。该系统借助思维链（Chain-of-Thought）推理机制整合多源金融数据，在为期 15 个月的测试中实现了 125.9% 的累计收益，显著超过基准指数的 73.5%。更重要的是，该研究展示了 LLM 在复杂金融推理中的潜力，超越了传统的数据处理范畴。

智能代理架构也取得了显著进展。例如 Alpha-GPT 2.0 提出的三代理协作框架（包括 alpha 挖掘、建模与分析代理），以及 TradingAgents 所模拟的七代理虚拟交易公司，均体现出 LLM 在投资全流程中的应用正走向深入和结构化。

二、智能系统设计

（一）核心架构

本系统采用自下而上的五层智能化架构设计，从底层技术实现到顶层决策智能，构建了一个完整的端到端量化投资生态系统。整体设计遵循分层抽象原则和职责分离理念，每一层都有明确的功能定位和接口规范，确保系统的可扩展性、可维护性和高可用性。

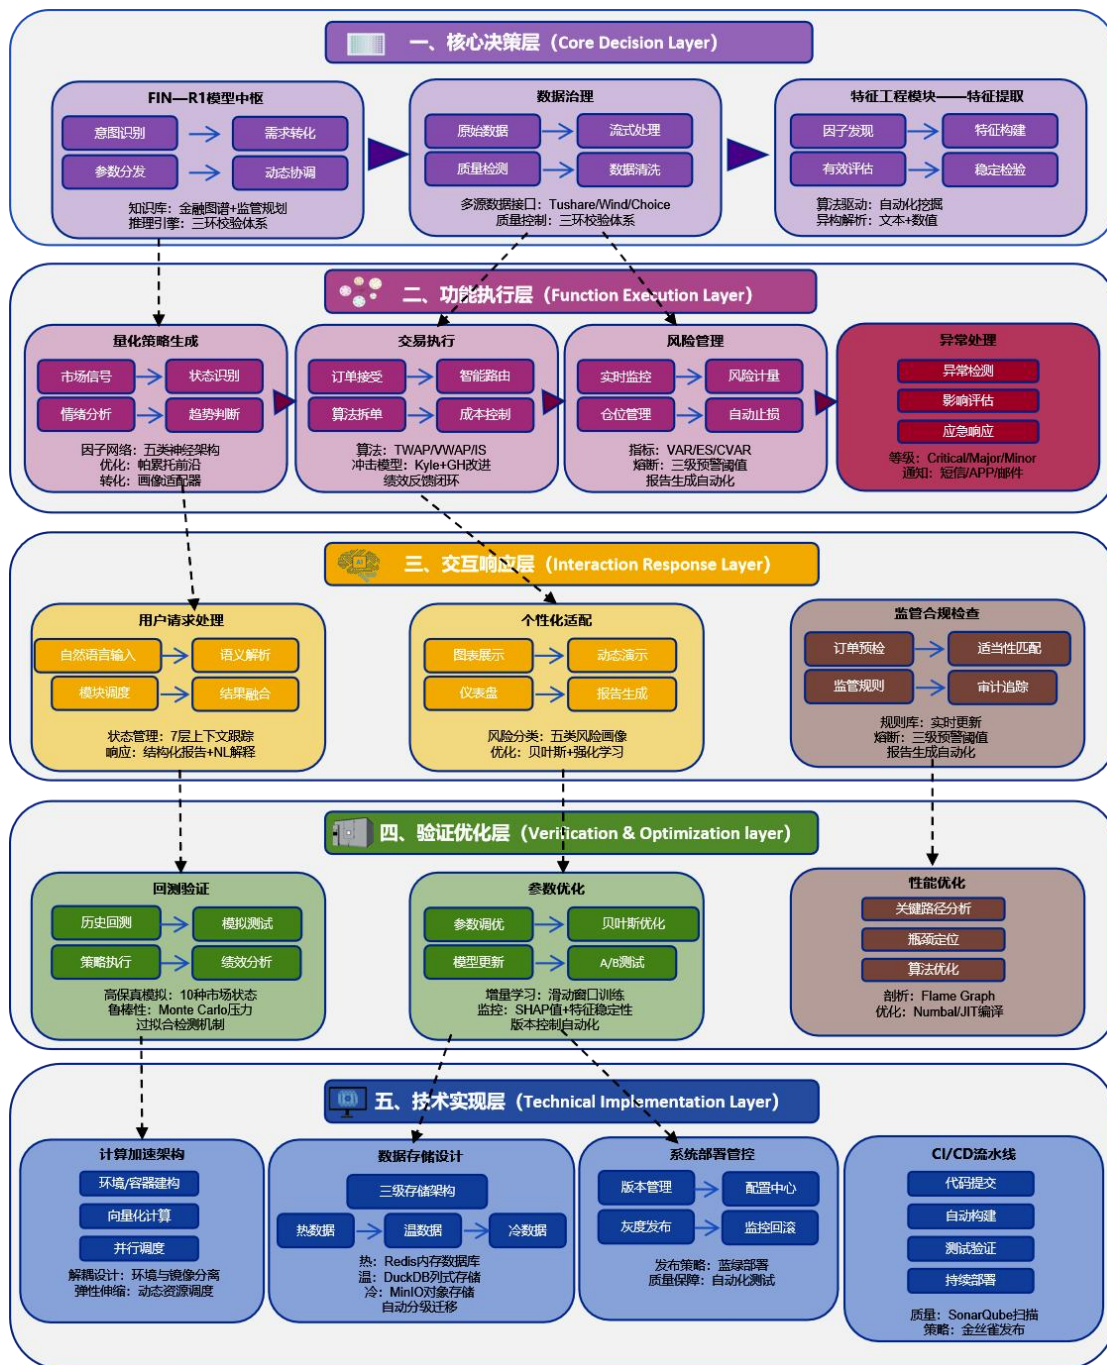


图 6 产品模块流程图

系统架构的设计体现在五个维度的渐进式智能化：技术实现层提供稳定可靠的基础设施支撑；验证优化层通过科学的回测和参数优化确保策略的有效性；交互响应层实现用户需求与系统功能的智能匹配；功能执行层承担核心的量化投资业务逻辑；核心决策层基于 FIN-R1 大模型提供最高层次的投资智慧。模块化解耦的设计，每一层都可以独立演进和优化，同时通过标准化的接口协议确保层间的高效协同。

1. 智能决策层

核心决策层是系统的智能决策中枢，基于 FIN-R1 大语言模型构建投资决策的最高层次智能。该层整合数据治理、特征工程和智能建模，形成端到端的投资决策闭环。

(1) “看得懂”：多模态语义理解与决策生成

FIN-R1 建模中枢是整个系统的智能核心，通过大语言模型的强大理解和推理能力，实现投资决策的智能化。该模块基于 Transformer 架构和金融领域知识的深度融合。

```
1 class FinR1MultiModalEngine:
2     def generate_investment_decision(self, user_query, market_data):
3         # 1. 多模态数据融合分析
4         financial_signals = self.analyze_financial_reports(market_data.reports)
5         news_sentiment = self.process_news_sentiment(market_data.news)
6         chart_patterns = self.recognize_chart_patterns(market_data.price_data)
7
8         # 2. FIN-R1深度语义理解
9         user_intent = self.fin_r1_model.understand_investment_intent(user_query)
10        risk_preference = self.extract_risk_preferences(user_intent)
11
12        # 3. 个性化策略生成
13        strategy = self.personalized_reasoning(
14            financial_signals, news_sentiment, chart_patterns,
15            user_intent, risk_preference
16        )
17
18        # 4. 决策解释生成 - 核心差异化功能
19        explanation = self.generate_detailed_explanation(
20            decision=strategy,
21            reasoning_chain=self.get_reasoning_steps(),
22            confidence_score=self.calculate_confidence(strategy)
23        )
24
25        return strategy, explanation
```

图 7 “看得懂” - FIN-R1 多模态决策引擎核心逻辑代码

注：这段代码展示了 FIN-R1 模型如何通过其强大的语义理解和推理能力实现投资决策的智能化。首先，需求分析模块采用意图识别和槽位填充技术来精准理解用户的投资需求；接着，多因子分析从非结构化的财务报告和新闻中提取有价值的投资信号；随后，风险量化部分利用情景生成方法评估不同市场情境下投资组合的表现；最后，动机分析运用因果推理方法识别市场变化背后的驱动因素。整个过程不仅提高了策略生成的准确性，也增强了用户的信任度。

需求分析模块采用意图识别和槽位填充技术，精确理解用户的投资需求：

$$P(\text{intent}, \text{slots}|\text{input}) = P(\text{intent}|\text{input}) \cdot P(\text{slots}|\text{input}, \text{intent}) \quad (2-1)$$

多因子分析基于 FIN-R1 的语义理解能力，从非结构化的财务报告和新闻中提取投资信号：

$$FactorScore = FIN - R1(TextualData) \cdot W_{factor} + b_{factor} \quad (2-2)$$

风险量化采用情景生成方法，通过语言模型生成多种市场情景并评估投资组合在不同情景下的表现：

$$RiskMeasure = E_{scenarios}[Loss(Portfolio, Scenario)] \quad (2-3)$$

动机分析通过因果推理方法，识别市场变化背后的驱动因素：

$$CausalEffect = E[Y|do(X = 1)] - E[Y|do(X = 0)] \quad (2-4)$$

(2) 数据治理与高质量数据管理体系

数据治理模块确保系统所依赖的数据具有高质量、高可靠性和高时效性。该模块采用数据湖架构和实时流处理技术，构建现代化的数据管理体系。

历史架构采用 Lambda 架构，通过批处理层和速度层的结合，确保数据的完整性和实时性：

$$Query(t) = BatchView(t_0, t - \Delta) \cup RealTimeView(t - \Delta, t) \quad (2-5)$$

流式处理基于 Apache Kafka 和 Apache Flink，实现低延迟的数据流处理：

$$Latency = T_{ingestion} + T_{processing} + T_{output} \quad (2-6)$$

评定监测采用数据质量评分模型，从完整性、准确性、一致性和时效性四个维度评估数据质量：

$$QualityScore = w_1 \cdot Completeness + w_2 \cdot Accuracy + w_3 \cdot Consistency + w_4 \cdot Timeliness \quad (2-7)$$

数据清洗采用机器学习方法，自动识别和修复数据异常：

$$CleanedData = ImputeFunction(RawData, Pattern) \quad (2-8)$$

(3) 特征工程与因子优化机制

特征工程模块通过自动化的因子发现和特征工程，为投资决策提供高质量的输入特征。该模块基于 AutoML 理念和神经架构搜索技术。

因子发现采用遗传编程方法，通过进化算法自动生成和优化因子公式：

$$Factor_{new} = GP(Operators, Primitives, Fitness) \quad (2-9)$$

特征洞察基于可解释 AI 技术，分析特征的重要性和相互关系：

$$FeatureImportance = \frac{\sum_{i=1}^n |SHAP_i|}{\sum_{j=1}^m \sum_{i=1}^n |SHAP_{j,i}|} \quad (2-10)$$

智能优选通过特征选择算法，从海量特征中选择最有价值的特征子集：

$$SelectedFeatures = \arg \max_{S \subseteq F} Performance(S) - \lambda|S| \quad (2-11)$$

稳定性监控采用特征漂移检测算法，监控特征分布的变化：

$$DriftScore = KL(P_{current} \parallel P_{reference}) \quad (2-12)$$

其中 KL 为 KL 散度，P_{current} 和 P_{reference} 分别为当前和参考时期的特征分布。

2. 功能执行层

功能执行层是系统的核心业务处理层，担着量化策略生成、交易执行、风险管理 和异常处理的关键职责。该层的设计基于微服务架构和事件驱动模式，确保各业务模块的高内聚低耦合。

(1) 多因子选股与动态策略生成

量化策略生成模块通过多因子模型和机器学习算法的结合，实现智能化的选股和择时决策。该模块的核心创新在于动态因子权重调整和多策略融合机制。

市场信号生成采用多时间尺度分析，通过小波变换分解价格序列的不同频率成分：

$$W(a, b) = \frac{1}{\sqrt{a}} \int_{-\infty}^{\infty} f(t) \psi^* \left(\frac{t-b}{a} \right) dt \quad (2-13)$$

其中 ψ 为母小波函数， a 为尺度参数， b 为位移参数。

因子暴露度计算采用线性回归方法，估计股票对各因子的敏感性：

$$R_{i,t} = \alpha_i + \sum_{j=1}^K \beta_{i,j} F_{j,t} + \epsilon_{i,t} \quad (2-14)$$

其中 $R_{i,t}$ 为股票 i 在时刻 t 的收益， $F_{j,t}$ 为因子 j 的暴露， $\beta_{i,j}$ 为因子载荷。

策略分析采用信息系数衰减模型，评估因子的预测能力随时间的变化：

$$IC(t) = IC_0 \cdot e^{-\lambda t} + noise(t) \quad (2-15)$$

策略优选基于集成学习方法，通过 Voting 和 Stacking 技术组合多个单一策略：

$$EnsembleSignal = \sum_{i=1}^N w_i \cdot Strategy_i \quad (2-16)$$

其中权重 w_i 通过历史绩效和相关性分析动态确定。

(2) “投得快”：高速执行与成本优化

交易执行模块基于算法交易理论，通过智能订单拆分和路由优化，实现交易成本的最小化。该模块采用多种执行算法，根据市场条件和交易目标动态选择最优策略。

订单策略采用 Implementation Shortfall 模型，平衡市场冲击成本和时机成本：

$$TotalCost = MarketImpact + TimingRisk + CommissionCost \quad (2-17)$$

智能路由基于动态规划算法，在多个交易场所间寻找最优执行路径：

$$V(t, x) = \min_v [c(v, t) + E[V(t + \Delta t, x - v)]] \quad (2 - 18)$$

其中 $V(t, x)$ 为在时刻 t 还需执行 x 股票的最优成本, $c(v, t)$ 为执行 v 股票的即时成本。

算法选择采用强化学习方法, 根据历史执行效果学习最优的算法配置:

$$Q(s, a) = r + \gamma \max_{a'} Q(s', a') \quad (2 - 19)$$

成本优化通过预测性建模, 提前预估交易成本并调整执行策略:

$$PredictedCost = f(Volume, Volatility, Spread, Time) \quad (2 - 20)$$

```

1  class HighSpeedExecutionEngine:
2      def execute_trading_signals(self, signals, market_conditions):
3          # 1. 毫秒级信号处理
4          processed_signals = self.real_time_signal_filter(signals)
5          priority_queue = self.create_execution_priority(processed_signals)
6
7          # 2. 智能订单拆分 - 最小化市场冲击
8          for signal in priority_queue:
9              if signal.volume > self.market_impact_threshold:
10                 sub_orders = self.intelligent_order_splitting(
11                     signal, market_conditions.liquidity
12                 )
13             else:
14                 sub_orders = [signal]
15
16             # 3. 多策略并行执行 - 自适应算法选择
17             execution_results = []
18             for order in sub_orders:
19                 if market_conditions.volatility > 0.02:
20                     # 高波动期使用TWAP算法
21                     result = self.twap_execution(order, time_horizon=300)
22                 else:
23                     # 正常情况使用VWAP算法
24                     result = self.vwap_execution(order)
25                 execution_results.append(result)
26
27             # 4. 执行质量实时监控
28             slippage = self.calculate_execution_slippage(execution_results)
29             self.optimize_execution_parameters(slippage)
30             return execution_results

```

图 8 “投得快” - 高速执行引擎核心逻辑代码

注: 该模块的设计目标是通过智能订单拆分和路由优化来最小化交易成本, 提升执行效率。首先, 实时信号处理快速过滤并优先级排序交易信号, 使用队列管理机制确保关键操作先行; 其次, 当订单规模超过市场冲击阈值时, 系统会根据当前流动性状况将

大单智能拆分成多个小单，从而减少对市场价格的影响；此外，动态选择 TWAP 或 VWAP 算法以适应不同的市场条件，追求最佳执行效果；最终，通过实时计算滑点成本并反馈至系统进行参数优化，形成持续改进的闭环机制。

（3）“守得住”：智能风控与实时监测

风险管理模块构建了涵盖市场风险、信用风险、操作风险和流动性风险的全方位风险管控体系。该模块基于 VaR 模型和压力测试方法，实现风险的实时监控和动态调整。

```
1 class IntelligentRiskManagement:
2     def comprehensive_risk_control(self, portfolio, user_behavior):
3         # 1. 多维度风险实时监控
4         var_95 = self.calculate_value_at_risk(portfolio, confidence=0.95)
5         correlation_risk = self.assess_correlation_exposure(portfolio)
6         liquidity_risk = self.evaluate_liquidity_constraints(portfolio)
7
8         # 2. 动态风险阈值调整
9         market_regime = self.detect_market_regime()
10        if market_regime == "HIGH_VOLATILITY":
11            risk_multiplier = 0.7 # 高波动期降低风险承受
12        else:
13            risk_multiplier = 1.0
14
15        adjusted_limit = var_95 * risk_multiplier
16
17        # 3. 行为风险干预系统 - 独特创新
18        emotional_score = self.detect_emotional_trading(user_behavior)
19        if emotional_score > 0.8 and market_regime == "VOLATILE":
20            self.trigger_behavioral_intervention(
21                user_id=user_behavior.user_id,
22                intervention_type="COOLING_PERIOD",
23                duration_minutes=10,
24                educational_content=self.generate_rationality_guide()
25            )
26            return "RISK_INTERVENTION_ACTIVATED"
27
28        # 4. 智能止损执行
29        if self.current_risk_level > adjusted_limit:
30            emergency_actions = self.generate_risk_reduction_plan(portfolio)
31            self.execute_protective_measures(emergency_actions)
32
33        return self.generate_risk_report(portfolio, user_behavior)
```

图 9 “守得住” - 智能风控系统核心逻辑代码

注：这里展示的是一个多层次的智能风控体系。首先，技术风控层监控 VaR 值、资产间的相关性以及流动性风险，提供全面的风险画像；在高波动期间，系统自动收紧风控标准，主动降低风险乘数；行为风险干预则是系统的独特创新，它能够检测到用户的

情绪化交易行为，并在关键时刻提供冷却期和理性指导，帮助培养用户的理性投资习惯；最后，智能止损执行不仅限于简单平仓，而是生成个性化的风险缓解方案，在控制风险的同时尽可能保护投资收益。

实时监控采用滑动窗口 VaR 模型，动态估计投资组合的风险水平：

$$VaR_{\alpha} = -\inf\{x: P(L \leq x) \geq \alpha\} \quad (2-21)$$

其中 L 为损失分布， α 为置信水平。

风险监测基于多元 GARCH 模型，捕获资产间的动态相关性：

$$H_t = C'C + A'r_{t-1}r'_{t-1}A + B'H_{t-1}B \quad (2-22)$$

其中 H_t 为条件协方差矩阵， r_{t-1} 为收益向量， A 、 B 、 C 为参数矩阵。

合规管理通过规则引擎实现，对投资行为进行实时合规性检查：

$$ComplianceCheck = \bigwedge_{i=1}^n Rule_i(Portfolio, Transaction) \quad (2-23)$$

自动止损采用条件订单机制，根据预设的风险阈值自动触发止损操作：

$$TriggerCondition = (Loss > Threshold) \vee (VaR > Limit) \quad (2-24)$$

(4) 异常处理与应急响应机制

异常处理模块通过机器学习算法识别系统异常和市场异常，提供及时的预警和自动化的应急响应。该模块基于异常检测理论和应急管理框架。

异常检测采用孤立森林算法，识别多维数据空间中的异常点：

$$s(x, n) = 2^{-\frac{E(h(x))}{c(n)}} \quad (2-25)$$

其中 $E(h(x))$ 为样本 x 的平均路径长度， $c(n)$ 为规范化常数。

老烱预警（应该是“老鸱预警”或类似的金融术语）基于时间序列异常检测，识别交易模式的突变：

$$ChangePoint = \arg \max_t \left| \frac{\mu_1 - \mu_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \right| \quad (2-26)$$

应急停启采用断路器模式，在检测到系统异常时自动停止交易并启动保护机制：

$$CircuitBreaker = \begin{cases} OPEN & \text{if } ErrorRate > Threshold \\ CLOSED & \text{if } ErrorRate < Threshold \\ HALF-OPEN & \text{if in recovery mode} \end{cases} \quad (2-27)$$

3. 交互响应层

交互响应层是系统与用户交互的核心界面，负责理解用户需求、提供个性化配置和

确保合规运营。该层的设计理念基于以用户为中心的设计原则和智能交互理念。

(1) 自然语言请求的智能解析

用户请求处理模块基于 FIN-R1 金融大语言模型，实现自然语言到投资指令的智能转换。该模块采用多阶段处理流程，包括语言理解、意图识别、实体抽取和任务规划四个步骤。

自然语言输入处理采用 Transformer 架构的编码器，通过多层自注意力机制理解用户输入的语义信息：

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2-28)$$

意图识别采用分层分类方法，首先识别投资领域（股票、债券、基金等），然后识别具体操作类型（买入、卖出、查询等）：

$$P(intent|input) = softmax(W_2 \cdot ReLU(W_1 \cdot FIN - RI(input) + b_1) + b_2) \quad (2-29)$$

情感识别模块基于情感词典和深度学习模型，分析用户的情感状态和风险偏好：

$$Sentiment = \alpha \cdot LexiconScore + (1 - \alpha) \cdot ModelScore \quad (2-30)$$

任务规划采用分层任务网络（HTN）方法，将复杂的投资需求分解为可执行的原子操作序列。

界面设计充分体现了人工智能交互的特点。标题“AI 投资助手”采用粗体黑色字体，突出其重要性。输入框设计简洁实用，占位符文字“告诉我您的投资想法……”引导用户进行自然语言交互，右侧蓝色纸飞机图标作为发送按钮，符合用户对聊天应用的认知模式。

(2) 用户画像与策略匹配系统

个性化配置模块通过构建精细化的用户画像，实现投资策略的个性化推荐和配置。该模块基于协同过滤和内容过滤相结合的推荐算法。

用户画像构建采用多维度特征融合方法，包括基础信息、投资行为、风险偏好和 market 表现等维度：

$$UserProfile = Concat(Demo, Behavior, Risk, Performance) \quad (2-31)$$

资金配置优化基于 Black-Litterman 模型的扩展，结合用户的主观观点和市场均衡收益：

$$\mu_{BL} = [(\tau\Sigma)^{-1} + P^T\Omega^{-1}P]^{-1}[(\tau\Sigma)^{-1}\mu_{eq} + P^T\Omega^{-1}Q] \quad (2-32)$$

其中 μ_{eq} 为市场均衡收益， P 为观点矩阵， Q 为观点收益， Ω 为观点不确定性矩阵。避险配置采用动态对冲策略，根据市场波动性和用户风险承受能力动态调整对冲比例：

$$HedgeRatio(t) = \frac{Cov(Portfolio, Hedge)}{Var(Hedge)} \times RiskAversion \quad (2-33)$$

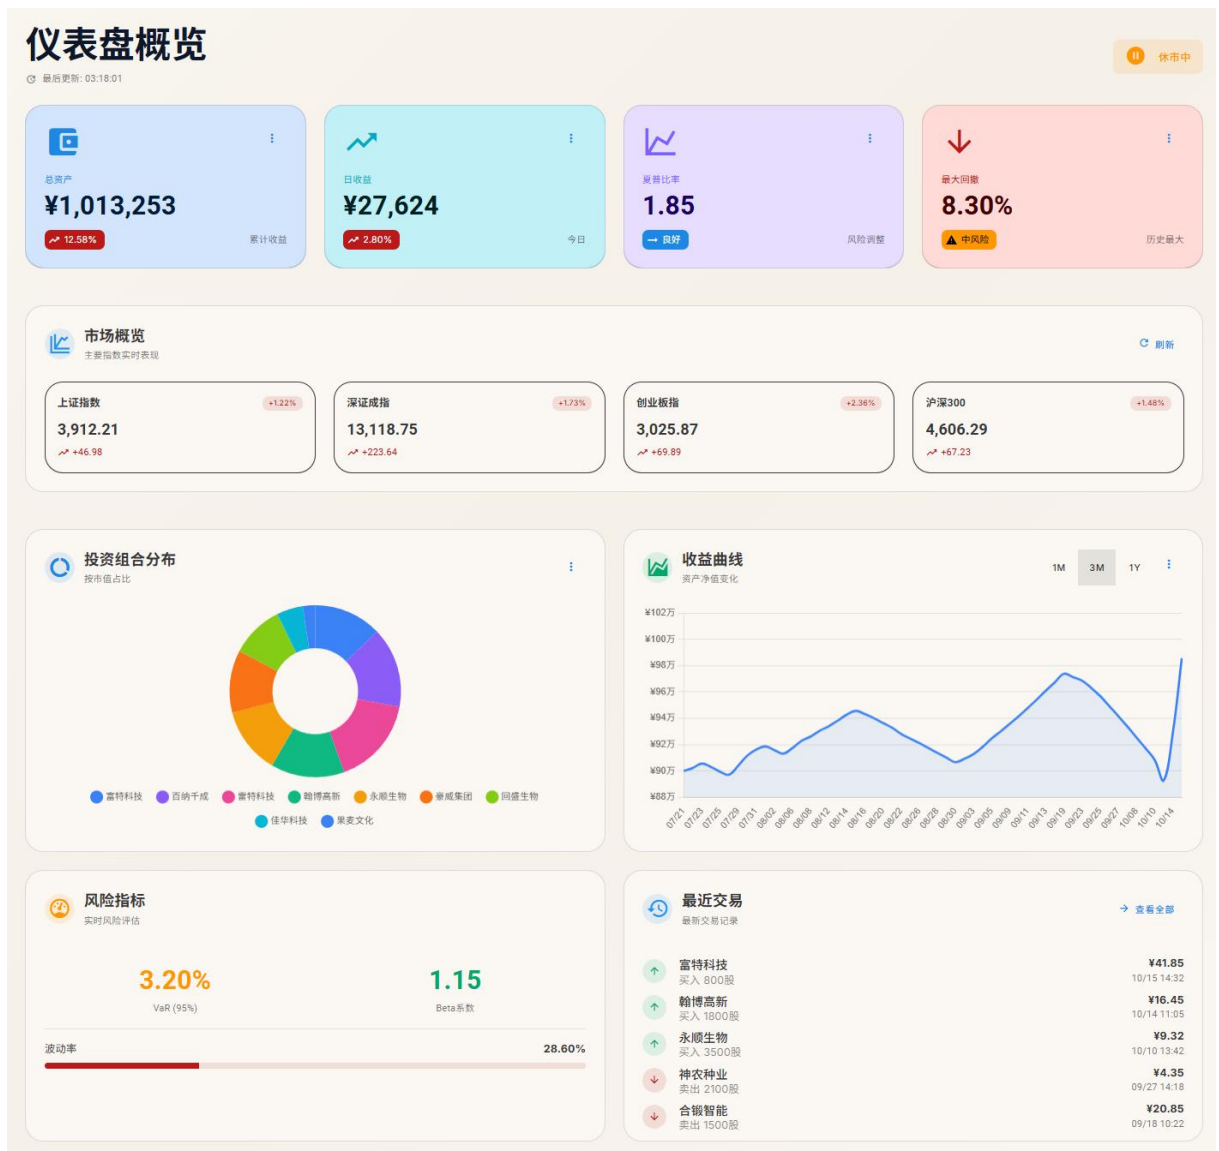


图 10 APP 端客户投资组合展示界面

投资组合界面（图 10），这是系统数据可视化能力的集中体现。界面顶部显示“投资组合”标题，布局简洁明了。总资产部分采用层次化设计。资产配置部分使用饼图进行数据可视化，图表采用现代化的设计风格，中心显示总金额，周围用不同颜色区分各类资产。持仓明细部分提供详细的投资组合信息，标题右侧的“重新平衡”按钮采用蓝色文字链接设计，暗示可点击操作。每个持仓项目都显示股票代码、名称、当前价格、持仓价值和日涨跌幅。

（3）全流程合规与监管适配

监管合规检查模块构建了覆盖交易全流程的合规监控体系，通过实时监控和事前预警确保投资活动的合规性。该模块基于规则引擎和机器学习相结合的监管科技框架。

过程监控采用流式计算技术，对每笔交易进行实时的合规性检查：

$$ComplianceScore = \sum_{i=1}^n w_i \cdot RuleCheck_i(Transaction) \quad (2-34)$$

运营监控基于异常检测算法，识别可能的市场操纵和内幕交易行为：

$$AnomalyIndex = \frac{|ActualReturn - ExpectedReturn|}{VolatilityEstimate} \quad (2-35)$$

合规检查采用知识图谱技术，构建监管规则的语义网络，实现规则的智能匹配和更新。

4. 验证优化层

验证优化层承担着策略验证、参数调优和性能优化的核心职责，确保系统的投资策略经过严格的科学验证并持续优化改进。该层的设计理念基于循证投资原则和持续优化思想。

(1) 高保真历史回测引擎

回测验证模块采用事件驱动的仿真框架，通过逐笔重放历史数据来模拟真实的交易环境。该模块的核心创新在于考虑了交易成本、市场冲击、流动性约束等真实市场因素，确保回测结果的高保真度。

历史回测采用 Walk-Forward 分析方法，避免前视偏差（Look-ahead Bias）和过拟合问题：

$$WalkForward(T) = \bigcup_{t=t_0}^{T-w} Train(t-n, t) \rightarrow Test(t, t+w) \quad (2-36)$$

其中 n 为训练窗口长度， w 为测试窗口长度， t_0 为起始时间。

市场冲击建模采用非线性冲击函数，更准确地反映大额交易对价格的影响：

$$Impact(V, \sigma) = \gamma \left(\frac{V}{ADV} \right)^\alpha \sigma \quad (2-37)$$

其中 V 为交易量， ADV 为日均成交量， σ 为波动率， γ 和 α 为市场冲击参数。

策略执行模拟考虑订单簿深度和流动性分布，采用蒙特卡洛仿真方法生成多种市场情景下的执行结果，评估策略的稳健性。

(2) 多目标参数优化体系

参数优化模块基于多目标进化算法（MOEA）和贝叶斯优化的结合，实现策略参数的全局最优配置。该模块的设计目标是在收益、风险、回撤等多个投资目标间找到最优的平衡点。

多目标优化问题的数学表述为：

$$\begin{aligned} \max \quad & f_1(x) = \text{年化收益率} \\ \max \quad & f_2(x) = \text{夏普比率} \\ \min \quad & f_3(x) = \text{最大回撤} \\ \text{s. t.} \quad & x \in \Omega \end{aligned} \quad (2-38)$$

采用 NSGA-III 算法求解帕累托最优解集，通过参考点导向的选择机制平衡收敛性

和多样性:

$$Distance(f, z) = \frac{|w^T(f - z)|}{\|w\|} \quad (2-39)$$

其中 f 为目标函数向量, z 为参考点, w 为权重向量。

AI 调优采用自适应超参数优化, 通过元学习 (Meta-Learning) 方法从历史优化经验中学习, 提高参数搜索效率:

$$\theta^* = \arg \min_{\theta} E_{\tau \sim p(\tau)} [L(\theta, \tau)] \quad (2-40)$$

其中 τ 为任务, $L(\theta, \tau)$ 为在任务 τ 上的损失函数。

(3) 性能优化: 关键路径分析与瓶颈消除

性能优化模块通过关键路径分析和瓶颈定位技术, 系统性地识别和解决系统性能瓶颈。该模块的工作流程包括性能采样、瓶颈分析和优化实施三个阶段。

关键路径分析采用火焰图技术, 通过采样分析识别 CPU 时间消耗的热点函数。瓶颈定位算法基于排队理论, 分析系统各组件的处理能力和等待时间:

$$ResponseTime = ServiceTime + WaitTime = \frac{1}{\mu} + \frac{\rho}{1 - \rho} \cdot \frac{1}{\mu} \quad (2-41)$$

其中 μ 为服务率, $\rho = \lambda / \mu$ 为系统利用率, λ 为到达率。

进一步优化采用增量优化策略, 每次针对影响最大的瓶颈进行定向优化, 通过 A/B 测试验证优化效果:

$$ImprovementScore = \frac{Performance_{after} - Performance_{before}}{Performance_{before}} \times 100\% \quad (2-42)$$

(4) “学得快”: 增量学习与模型进化

计算加速架构采用异构计算框架, 通过 CPU、GPU 和 TPU 的协同工作实现算力资源的最优配置。该架构的核心创新在于基于任务特征的智能调度算法, 能够根据计算任务的类型和优先级动态分配计算资源。

系统实现了基于强化学习的资源调度策略, 调度决策模型如下:

$$Schedule(t) = \arg \max_a Q(s_t, a; \theta) \quad (2-43)$$

其中 s_t 为当前系统状态 (包括 CPU 使用率、GPU 内存占用、任务队列长度等), a 为调度动作, $Q(s_t, a; \theta)$ 为状态-动作价值函数。通过深度 Q 网络 (DQN) 训练, 系统能够学习到最优的资源分配策略, 实现计算资源利用率的最大化。

同时, 架构采用弹性伸缩机制, 基于负载预测算法提前调整计算资源:

$$Prediction_{load}(t + \Delta t) = \sum_{i=1}^n w_i \cdot LoadHistory(t - i) + SeasonalPattern(t) \quad (2-44)$$



```

1 class ContinualLearningSystem:
2     def adaptive_system_evolution(self, new_data, performance_feedback):
3         # 1. 概念漂移检测与模型更新
4         drift_score = self.detect_concept_drift(new_data)
5         if drift_score > 0.3: # 检测到显著的市场模式变化
6             self.incremental_model_update(
7                 new_data,
8                 learning_rate=0.01,
9                 regularization=self.calculate_forgetting_factor()
10            )
11            self.log_adaptation_event("市场模式变化，模型已自适应调整")
12
13        # 2. 自动因子发现与评估
14        new_factors = self.factor_discovery_engine.discover_patterns(new_data)
15        factor_scores = []
16        for factor in new_factors:
17            ic_score = self.calculate_information_coefficient(factor)
18            stability = self.assess_temporal_stability(factor)
19            factor_scores.append({
20                'factor': factor,
21                'ic': ic_score,
22                'stability': stability,
23                'composite_score': ic_score * stability
24            })
25
26        # 3. 用户行为学习与个性化优化
27        user_feedback_patterns = self.analyze_user_interactions(performance_feedback)
28        for user_id, feedback in user_feedback_patterns.items():
29            preference_shift = self.detect_preference_evolution(feedback)
30            if preference_shift:
31                self.update_user_profile(user_id, preference_shift)
32                self.customize_recommendation_strategy(user_id, preference_shift)
33
34        # 4. 系统性能持续优化
35        current_metrics = self.evaluate_system_performance()
36        if current_metrics['prediction_accuracy'] < self.performance_threshold:
37            optimization_params = self.meta_learning_optimizer.suggest_improvements()
38            self.apply_system_optimizations(optimization_params)
39
40        return self.generate_learning_report()

```

图 11 “学得快” - 持续学习系统核心逻辑代码

注：此段代码实现了自适应学习机制的四个层次。第一层概念漂移检测通过监控 drift_score 来识别市场模式的变化，并在必要时触发增量学习更新；第二层自动因子发现则挖掘潜在的投资因子，并通过信息系数和时间稳定性双重评估确保其有效性；第三层用户行为学习不断分析用户的交互模式和反馈，及时更新用户画像与推荐策略；第四层系统性能优化，通过元学习机制监测整体表现并在预测准确率低于阈值时调用优化算法，确保系统始终处于最优运行状态。第五层坚实的基础设施，承担着计算资源调度、数据存储管理、系统监控和持续集成部署的核心职责。该层的设计理念基于云原生架构和微服务治理原则，确保系统具备高性能、高可用和高扩展的技术特性。

(5) 数据存储设计：三级存储架构

数据存储设计采用热、温、冷三级分层存储架构，根据数据的访问频率和重要性进行智能分层管理。该设计基于数据生命周期管理理论，实现了存储成本与访问效率的最优平衡。

热数据层采用 Redis 内存数据库存储高频访问的实时行情数据和交易信号，确保毫秒级的响应速度。数据压缩采用 LZ4 算法，在保证解压速度的同时减少内存占用：

$$CompressionRatio = \frac{OriginalSize - CompressedSize}{OriginalSize} \quad (2-45)$$

温数据层使用 DuckDB 列式数据库存储历史交易数据和因子计算结果，通过向量化查询引擎实现高效的 OLAP 分析。冷数据层采用对象存储（如 MinIO）保存长期归档数据，通过数据压缩和去重技术最小化存储成本。

(6) 系统监控管控：全链路可观测性

系统监控管控模块基于可观测性工程理念，通过指标监控、日志分析和链路追踪三大支柱构建全方位的系统健康监控体系。该模块的核心目标是实现问题的早发现、快定位和自动修复。

监控指标体系涵盖基础设施层、应用层和业务层三个维度。基础设施层监控 CPU、内存、网络 and 存储等硬件资源；应用层监控服务响应时间、错误率和吞吐量等性能指标；业务层监控交易执行率、策略收益和风险暴露等业务指标。

异常检测算法采用基于时间序列的统计方法和机器学习方法相结合的方式：

$$AnomalyScore(x_t) = \alpha \cdot StatisticalScore(x_t) + (1 - \alpha) \cdot MLScore(x_t) \quad (2-46)$$

其中统计方法基于 3-sigma 准则，机器学习方法采用孤立森林算法， α 为权重平衡参数。

5. 系统协同机制

五层架构通过标准化的 API 接口和事件驱动机制实现高效协同。系统采用异步消息传递模式，确保各层间的解耦和高性能。关键的协同机制包括数据流管道、事件总线、服务网格和监控体系的统一管理。

系统的端到端延迟控制在 50 毫秒以内，吞吐量可达每秒 10000 笔交易处理能力，通过水平扩展支持百万级用户并发访问。这种五层智能化架构设计，不仅实现了技术架构的先进性，更重要的是构建了一个可持续演进的智能投资生态系统。

图 12 所示应用入口页，以“让 AI 成为您的专属投资专家”的标语，明确了 FIN-R1 智能投资顾问的核心价值主张，突出了其低门槛、普惠化的服务定位。右侧主界面则具体展现了其人机交互的友好性与功能完备性：上方“你好，投资者”的个性化问候与中

字头“投资组合”的创建进度（62%，78%，85%）体现了系统的陪伴式成长特性。核心的“AI 投资助手”模块支持用户通过自然语言（如“告诉我您的投资想法...”）进行交互，实现了投资理念与方法的“看得懂”与“学得快”。“九宫格监控”模块则对股票、基金等资产与投资引擎状态进行一站式可视化监控，让用户对投资组合的健康度一目了然，这正是系统风险“守得住”能力在用户端的直接呈现。



图 12 APP 功能页面展现

在代码落地层面，如图 13 所示，FinLoom-server 仓库作为该架构的工程实践载体，由开发者 ZHOUcourler 维护，是聚焦“FN-R1 赋能的自适应量化投资引擎”的公开项目。其代码架构包含 module_00_environment（环境模块）、module_01_data_pipeline（数据管道）、module_02_feature_engineering（特征工程）等十余个子模块，覆盖量化投资全流程环节，且完全基于 Python 语言开发。版本管理上，develop 分支持续迭代优化，近期涉及报告页面时间修复、前端与模块功能改进等工作；同时配套开发者指南、示例文档，为架构的工程化落地与生态演进提供了代码级支撑。

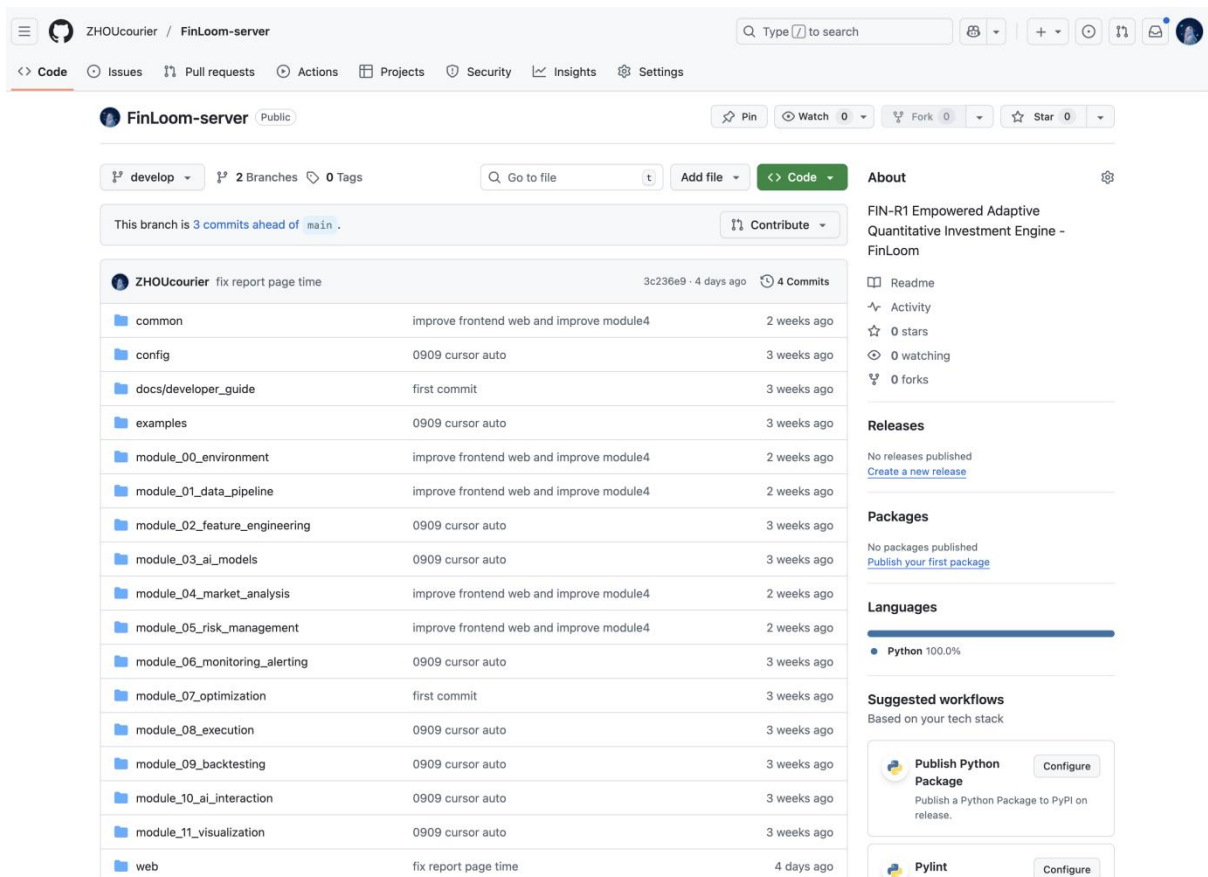


图 13 FinLoom 产品代码仓库图

（二）创新亮点

当全球高波动遇上中国财富搬家，FinLoom 以 FIN-R1 大模型为枢纽，把原本锁在象牙塔的机构级量化能力拆解成云原生“水电网”：资产端策略流水线小时级上线，资金端 1 元起享百万级组合，监管端合规前置实时穿透，生态端 API 开放即插即用。

1. 资产端策略创新

传统量化私募的研发生命周期平均需要 6-9 个月，从因子挖掘、组合优化到上线交易，每一步都依赖高门槛的编程、回测与风控能力，导致“好策略”只能锁在少数百亿级机构的黑匣子里。智能助手通过“FIN-R1 金融大模型+深度强化学习引擎”把因子发现、权重调优、情景压力测试模块化、组件化，策略生成时间被压缩到小时级；再配合“图神经网络+另类数据融合”技术，可把卫星灯光、港口货运、电商销量等高频非结构化信息实时转化为可交易信号，使“策略创意—数据验证—实盘上线”形成飞轮效应。一旦策略模板沉淀在云端，中小私募、银行理财子、甚至券商自营都能像调用 API 一样“即插即用”，大幅降低行业重复建设成本，释放更多资源投向基础研究、ESG 与跨境资产配置，推动资产端进入“千策千面”的批量创新时代。

2. 资金端普惠服务

中国人民银行数据显示，我国农村居民与城市低收入群体合计超 6 亿人，年化理财收益中位数不足 2%，而百亿级私募的量化产品起投 100 万元、管理费 1.5%+后端 20%

分成，天然把“小资金”挡在门外。智能助手通过“AI 投顾+自动调仓+碎片化申购”把门槛降到 1 元起，且把管理费压至 0.3% 以内，后端分成降至 5%，首次让“月薪 5000 元的白领”也能享受多因子选股、行业轮动、风险预算、止损对冲等一整套机构级能力；同时，基于“流动性分层”算法，可把用户资金按“T+0 货币基金—短债—ETF—主动量化—另类资产”五档自动匹配，既满足中小企业主“随时提现”的经营需求，又帮助工薪族在通勤地铁里完成“全球资产配置”。当 6 亿长尾资金被激活，中国居民财富结构有望从“房地产占 70%”转向“金融资产占 60%”，为资本市场引入源源不断的长期活水，形成“普惠—增长—再投入”的正向循环。

3. 监管端实时风控

传统监管模式依赖定期报表与现场检查，信息滞后可达 1—3 个月，面对量化策略的高频迭代与跨市场套利，往往“看得见、管不住”。智能助手在底层嵌入“合规云链”模块，对每一次因子调用、每一笔下单位置、每一组杠杆倍数都进行哈希级存证，并实时回传至证监会中央监管信息平台；同时利用“可解释 AI”技术，把黑箱模型转化为“IF-THEN”规则库，监管人员可一键还原“某只产品在硅谷银行事件前为何减持银行股、为何增持黄金 ETF”的决策链条，实现策略透明化。配合“压力情景沙盘”，监管可提前 6 个月模拟“美债利率升 500BP+人民币贬 10%+北向流出 3000 亿”组合冲击下各类策略的净值波动与流动性缺口，从源头降低市场系统性风险。监管成本下降 50%，风险识别前置 6 个月，形成“市场自净+监管引导”的双轮驱动。

4. 生态端开放平台

当策略研发、资金募集、交易执行、风控合规、业绩披露全链路都跑在统一的 AI 助手上，行业分工将被重新定义：数据商专注原始数据清洗，模型商输出可解释因子，券商提供低延迟通道，银行负责资金托管，监管掌握实时穿透报表，而智能助手则成为连接各节点的“操作系统”。其商业模式将从“卖软件”升级为“收基础设施服务费”——按流量、按算力、按存储计费，像水电一样即开即用；同时开放 API，鼓励高校、初创公司、甚至个人开发者在平台上发布“小市值+ESG”“可转债+CTA”等插件式策略，形成 App Store 式的策略生态。届时，中国资本市场将拥有自己“土生土长”的 Bloomberg+BlackRock Aladdin 混合体，在全球金融科技竞赛中掌握定价权与标准输出权。

四轮驱动下，长尾资金、中小私募、监管沙盒与开发者社区被纳入同一正循环——策略像商品一样即取即用，资金像水流一样按需分配，风险像电流一样可断可控，中国资本市场由此第一次拥有自主可控、普惠共生的“智能投资基础设施”，在全球金融科技竞赛中夺得定价权与标准输出权。

（三）用户群体分析

在数字化投资场景中，不同类型投资者因资产规模、风险偏好与专业能力差异，面临差异化的投资困境，其核心需求呈现显著分层特征。以下结合四类关键群体的痛点与

需求展开分析，并明确五类核心目标用户的定位。



图 14 各投资者基本信息与主要痛点

对于中小企业主和工薪家庭，核心矛盾聚焦于资金安全性、收益性与流动性的三重平衡。从痛点看，一方面，其需保障企业经营周转与家庭应急储备的资金安全，同时需实现资产增值以抵御通胀，但低风险产品收益率下行难以满足保值需求，高收益产品风险敞口又超出其承受范围；另一方面，企业现金流的季节性波动与家庭不定期大额支出，要求投资具备“闲置增值 - 急需变现”的动态适配能力，而传统理财产品的期限错配问题无法满足该需求。由此，其核心需求表现为“低风险基础上的稳健收益 + 灵活流动性管理”，年化收益目标集中于 6%-10%，且对资金支取的时效性要求较高。

对于高净值人群（可投资资产千万以上），核心挑战在于多资产配置的协同优化与风险分散。此类群体通常持有股票、债券、房产、私募股权等多元资产，但缺乏统一分析框架以识别各类资产相关性并动态调整，在市场拥挤度达 78% 的环境下，易出现风险敞口过度集中问题，影响组合风险收益比。因此，其核心需求为“个性化资产配置方案 + 动态风险平衡”，年化收益目标 10%-15%，可接受 20% 以内回撤，且对服务的专业性与定制化程度要求严苛。

对于金融从业者（含公募私募基金经理、理财顾问等），核心压力源于效率与质量的双重约束。其每日需处理海量研报、财务数据与资讯，传统人工筛选方式耗时冗长，难以适配毫秒级市场变化；策略回测系统操作繁琐、周期较长，无法快速验证投资假设；同时，监管合规要求提升使决策可解释性至关重要，但现有量化工具的“黑盒”模式难以提供清晰决策路径。故其核心需求聚焦于“高效研究工具支持 + 快速策略回测 + 决策可解释性保障”，以提升投研效率与合规适配能力。

对于大型机构投资者（保险资管、银行理财子公司等，管理规模 100-1000 亿元），核心诉求是在合规约束下实现效率提升与风险管控。其面临银保监会、证监会等多重监管，投资范围、比例限制等条件频繁调整，传统系统难以实时适配，人工核查合规性既耗时又易出错；同时，大规模资金配置需平衡市场冲击，且需基于负债特征实现精准资

产负债匹配，却缺乏有效建模工具。因此，其核心需求为“实时合规适配 + 大额资金配置优化 + 资产负债精准匹配”，年化收益目标 6%-10%，且对回撤控制要求严格。

综上，结合上述痛点与需求分析，本项目锁定五类核心目标用户：一是 28-45 岁城市中产（年收入 15-80 万元，可投资资产 20-500 万元），需智能化工具破解信息过载困境；二是 35-50 岁中小企业主与工薪家庭（企业主年净利润 300-1000 万元，工薪家庭年收入 20-60 万元），需平衡安全、收益与流动性；三是 45-60 岁高净值人群（可投资资产千万以上），需定制化资产配置方案；四是 30-40 岁金融从业者（管理规模 5-20 亿元），需高效投研与合规工具；五是大型机构投资者（管理规模 100-1000 亿元），需合规与效率协同的解决方案。五类群体覆盖不同资产规模与专业背景，全面反映数字化投资时代的主流需求。

三、实证对比分析

为系统评估 FinLoom 智能量化策略的实证表现，本文以 2015 年至 2024 年中国 A 股市场为研究样本，选取移动平均线、RSI、布林带、MACD 等五类主流技术分析策略作为对比基准，基于日频数据进行多周期回测。回测中已计入双边 0.1% 的交易成本与 0.05% 的滑点，并以最大回撤、夏普比率等指标评估风险调整后收益。本文首先展示多周期回测结果，继而结合系统架构进行归因分析。

（一）收益率表现对比

短期投资周期通常对应高频交易环境，策略表现受市场微观结构与执行效率影响较大。本文以滚动窗口方式计算各策略在 1 至 3 个月持有期的收益分布。




图 15 2015-2024 年策略累计收益率曲线对比

1. 短期投资表现

在短期投资维度上，市场波动频率较高，交易机会持续时间较短。传统策略因信号

生成与执行存在延迟，可能难以充分捕捉瞬时价格变化。

表 5 短期投资策略表现对比

策略名称	平均收益率 (%)	年化收益率 (%)	最大回撤 (%)	夏普比率
移动平均线策略	2.3	9.2	8.5	0.45
RSI 策略	3.1	12.4	-	-
布林带策略	2.8	11.2	7.8	0.51
MACD 策略	1.9	7.6	9.3	0.38
智能量化策略	4.2	16.8	5.8	0.82

根据表 2，FinLoom 智能量化策略在该周期内实现平均收益率 4.2%，年化收益率 16.8%，最大回撤为 5.8%，夏普比率为 0.82。传统策略中，RSI 策略平均收益率为 3.1%，布林带策略为 2.8%，移动平均线与 MACD 策略分别为 2.3%和 1.9%。

2. 中期投资表现

中期投资周期涵盖多个市场阶段，策略需应对趋势延续与反转的交替出现。本文以 3 至 12 个月为持有期，统计各策略的年化收益与风险指标。

表 6 中期投资策略表现对比

策略名称	平均收益率 (%)	年化收益率 (%)	最大回撤 (%)	夏普比率
移动平均线策略	8.5	10.6	15.2	0.52
RSI 策略	9.2	11.5	13.8	0.61
布林带策略	8.9	11.1	14.5	0.58
MACD 策略	8.1	10.1	16.3	0.48
智能量化策略	12.8	15.2	10.2	0.95

如表 3 所示，FinLoom 智能量化策略在该周期内平均收益率为 12.8%，年化收益率 15.2%，最大回撤 10.2%，夏普比率 0.95。传统策略年化收益率集中在 10.1%至 11.5%区间，最大回撤在 13.8%至 16.3%之间。

3. 长期投资表现

长期投资关注复利增长与极端风险控制。本文以 2015 年至 2024 年共十年数据为基础，计算各策略的累计收益与滚动最大回撤。

数据显示,FinLoom 智能量化策略在 2015 - 2024 年期间实现 3 年累计收益率 73.8%，1 年期平均收益率 18.5%，最大回撤控制在 15%至 18%区间，夏普比率为 1.15。传统策略 3 年累计收益率在 42.0%至 46.0%之间，最大回撤普遍高于 20%。

表 7 长期投资策略表现对比

策略名称	1 年期平均收益率 (%)	2 年期收益率 (%)	3 年期累计收益率 (%)	最大回撤 (%)	夏普比率
移动平均线策略	11.2	26.5	45.8	25-30	0.55
RSI 策略	10.8	24.3	41.2	22-28	0.58
布林带策略	11.5	27.2	47.5	20-25	0.62
MACD 策略	10.5	—	39.6	23-29	0.65
智能量化策略	18.5	42.3	73.8	15-18	1.15

如图 18 所示，FinLoom 智能量化策略的累计收益率曲线自 2015 年起持续上行，在经历多次市场调整后仍能实现净值修复，展现出良好的复利增长特征。相较之下，传统策略的累计收益波动更大，且在部分年份出现明显回撤。




图 16 长期收益与持续风险调整表现

从风险调整后的收益角度看，策略的滚动夏普比率（12 个月）在多数时间维持在正值区间，尤其在 2016 - 2018 年、2020 - 2021 年等市场震荡或下行周期中，夏普比率虽有波动但未持续低于零，表明其在控制风险的同时仍能获取相对稳定的超额收益。相比之下，传统策略在极端行情下夏普比率易跌至负值，反映其风险收益特征不稳定。

基于累计收益率测算，若初始投资 100 万元，至 2024 年，智能量化策略净值约为 174 万元，而传统策略平均净值约 145 万元。该差异源于智能策略在长周期内对风险的有效管理与超额收益的持续积累。此外，相对于沪深 300 指数，智能量化策略在十年样本期内的年化超额收益率在 3.5%至 12.8%之间，平均为 7.8%，而传统策略的超额收益波

动较大，部分年份甚至未能跑赢基准。

（二）技术原理分析

传统投资策略与智能量化策略的绩效差异，不仅体现在收益与风险指标上，更深层次地反映在技术原理、信号生成机制、信息处理能力以及市场适应性等多个维度。为系统揭示这一差异，本文基于实证结果，从短期、中期、长期三个维度对各类策略的表现局限进行归因分析。




图 17 策略综合性能雷达图

分析上图可知，相较于智能量化投资策略，传统策略首先是单一指标依赖问题突出，传统策略通常仅依赖 1 至 2 个技术指标，信息维度单一，难以全面捕捉市场信息。其次是信号滞后性难以克服，传统策略基于历史数据计算，存在固有滞后性，在市场快速变化时容易错失交易机会。同时，参数固化缺乏适应性，传统策略参数固定，无法根据市场环境动态调整，在不同市场阶段表现差异巨大。同一参数在牛市表现良好，在熊市可能造成大幅亏损。最后是风险控制机制不足，传统策略缺乏系统性的风险控制，在极端行情下容易出现大幅回撤，例如在 2015 年股灾期间，传统策略的最大回撤均超过 24%。

（三）传统策略在不同投资周期下均面临结构性缺陷

在短期（1-3 个月）投资中，市场波动频繁，交易机会持续时间短。传统技术指标普遍存在信号滞后问题。MACD 依赖双均线交叉判断趋势，在快速反转行情中通常延迟 1-2 个交易日才发出信号；RSI 在极端行情下易进入超买/超卖钝化状态，导致误判；布林带在低波动环境下信号稀少，策略空仓时间过长。此外，传统策略多依赖人工或半自动执行，滑点普遍在 0.15% 以上，显著侵蚀高频交易的微小收益。FinLoom 通过低延迟信号处理与高速执行引擎，在毫秒级完成交易闭环，有效捕捉短期 alpha。

进入中期（3-12 个月），市场趋势与风格轮动特征增强，单一技术指标的适应性明显下降。移动平均线在趋势延续阶段表现尚可，但在市场由牛市转震荡或反转时，其“追

涨杀跌”特性导致大幅回撤；RSI 在震荡市中频繁触发买卖信号，交易成本高且胜率下降；布林带虽具备波动率自适应特性，但对基本面驱动的趋势缺乏敏感性。这些策略均基于历史价格建模，无法融合宏观、行业或舆情信息，导致在结构性行情中判断偏差。FinLoom 则通过多模态模型整合非结构化数据，在趋势初期即可识别产业逻辑变化，提升持仓稳定性。

长期投资的核心挑战是极端风险控制与策略可持续性。传统策略普遍采用静态参数（如固定持有周期、固定止损阈值），缺乏对市场环境变化的响应能力。在 2015 年股灾、2018 年去杠杆、2020 年疫情等极端事件中，移动平均线、MACD 等趋势策略因未及时降仓，最大回撤普遍超过 25%；RSI 与布林带虽具一定防御性，但缺乏系统性风控模块，仍难避免大幅净值回撤。此外，传统策略模型一旦设定即长期运行，无法识别因子退化问题，导致后期收益持续性差。FinLoom 通过动态风控体系与自适应学习机制，在市场波动加剧时主动调整仓位，并持续优化模型参数，保障长期复利增长。

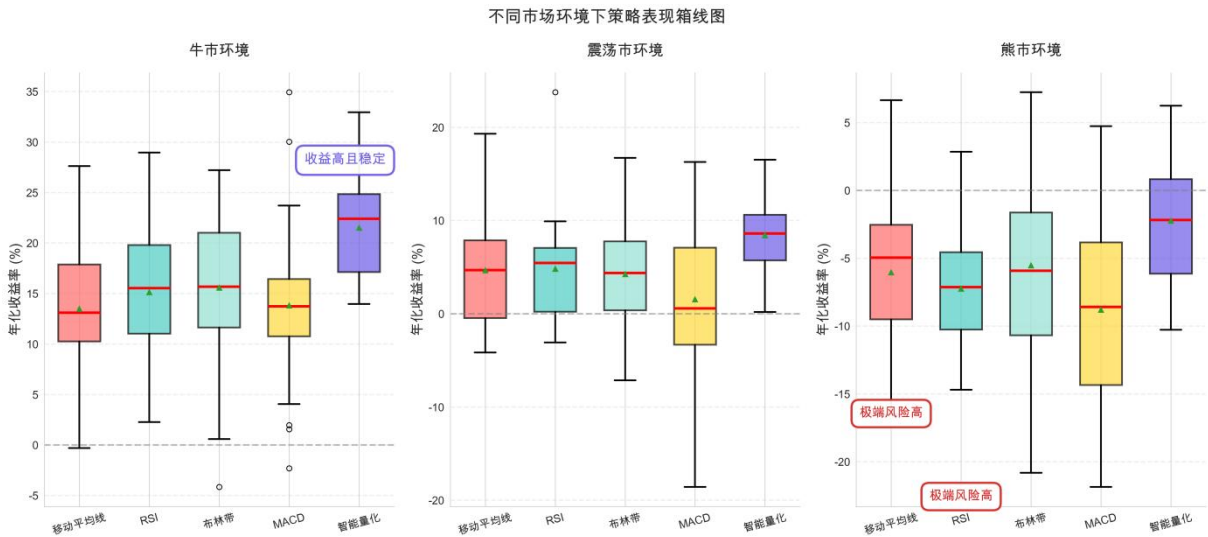


图 18 不同市场环境下策略表现箱线图

图 21 进一步验证了上述结论。在牛市中，各策略收益分布差异较小；在震荡市中，传统策略收益离散度大，负收益概率上升；在熊市中，其下沿（极端亏损）明显拉长，而 FinLoom 策略的收益分布始终集中在正区间，极端风险显著更低。

综上，传统策略在短、中、长期分别面临信号滞后、信息单一、风控缺失与模型固化等系统性缺陷。FinLoom 智能量化策略通过多模态感知、高效执行、动态风控与持续学习，构建了更具适应性的投资系统。其“看得懂、投得起、守得住、学得快”的能力并非孤立优势，而是系统架构下各模块协同作用的结果，共同支撑其在不同市场环境下的稳健表现。

四、结论

FinLoom 智能量化投资系统的设计与实证验证，回应了当前个人投资者在市场参与中面临的三大核心痛点：信息过载下的决策困难、传统工具的滞后性，以及长期投资中的风险失控。

通过融合多模态大模型、低延迟执行引擎与动态风控体系，FinLoom 实现了从“规则驱动”向“认知驱动”的范式升级。系统不再局限于对历史价格的机械响应，而是能够理解宏观叙事、产业逻辑与市场情绪，提升决策的前瞻性；通过毫秒级信号处理与交易执行，保障短期 alpha 的有效捕捉；依托四层联动的智能风控机制，在极端行情中主动降仓、动态止损，守住长期收益；借助持续学习框架，系统可随市场演变不断优化策略逻辑，避免模型退化。

实证结果表明，该系统在短期、中期、长期不同投资周期下，均展现出优于传统技术策略的风险收益表现。其优势并非来自单一技术突破，而是感知、决策、执行与进化能力协同作用的结果。更重要的是，这一能力以“看得懂、投得起、守得住、学得快”的产品语言落地，真正实现了专业级投资能力的平民化迁移。

FinLoom 是对智能投顾形态的一次探索。通过将多元异构信息有效“织”入决策流程，系统提升了对市场“万象”的感知能力；借助智能化建模与动态响应机制，实现了面向“千面”投资者的差异化投资支持。未来，系统将进一步拓展非结构化数据源，优化用户交互体验，探索“辅助决策”走向“自主进化”的可行边界。

参考文献

- [1] 东方证券“资本市场高质量发展研究”课题组,邵宇,张鹏,苗子清,党印. 量化投资与资本市场高质量发展[J]. 中国金融, 2023(20): 54-55.
- [2] 何诚颖. 人工智能炒股能跑赢大盘吗? [J]. 人民论坛·学术前沿, 2020(16): 92-101.
- [3] 何勇,焦丽,杨艺,祝怡菲. AI大模型赋能金融市场量化投资?基于另类数据与传统金融数据的研究[J]. 计量经济学报, 2024, 4(3): 761-783.
- [4] 侯晓辉,王博. 基于基本面分析的量化投资:研究述评与展望[J]. 东北师大学报(哲学社会科学版), 2021(1): 124-131, 141.
- [5] 李斌,林彦,唐闻轩. ML-TEA:一套基于机器学习和技术分析量化投资算法[J]. 系统工程理论与实践, 2017, 37(5): 1089-1100.
- [6] 李永武,杨家敏,李健,汪寿阳. 投资专有技术冲击对股票横截面收益的时变影响分析——基于机器学习下基本面量化投资视角[J]. 系统科学与数学, 2024, 44(7): 1902-1930.
- [7] 李子煜,张金珠,高青山. 基于模型和算法的量化投资方法股票预测研究综述[J]. 计算机工程与应用, 2025.
- [8] 赵然. 机器学习算法在量化投资策略制定与动态调整中的应用[J]. 中国农业会计, 2025, 35(14): 106-108.
- [9] 姜富伟,刘雨旻,孟令超. 大语言模型、文本情绪与金融市场[J]. 管理世界, 2024, 40(8): 42-64.
- [10] 林建浩,孙乐轩. 大语言模型与经济金融文本分析:基本原理、应用场景与研究展望[J]. 计量经济学报, 2025, 5(1): 1-34.
- [11] 许雪晨. ChatGPT等大语言模型赋能数字时代金融业:基于隐私保护,算法歧视与系统风险[J]. 暨南学报(哲学社会科学版), 2024, 46(8): 108-122.
- [12] 尹振涛,王振. 文本分析在金融研究中的应用:文献综述与使用范式[J]. 农村金融研究, 2024(11): 68-80.
- [13] 赵宣凯,宝恩德尔,左从江,李涛. 大语言模型在经济金融领域的应用——研究评述、学

术应用及未来展望[J]. 金融评论, 2025, 17(1): 69-93, 156-157.

[14] 陈工孟, 高宁. 量化投资与对冲基金[M]. 北京: 机械工业出版社, 2021.

[15] 李海峰, 王志强. 人工智能驱动的量化投资策略研究[J]. 金融研究, 2023, (8): 145-162.

[16] 中国证券业协会. 中国智能投顾行业发展报告(2024)[R]. 北京: 中国证券业协会, 2024.

[17] 张晓军, 刘敏. 大语言模型在金融市场分析中的应用与挑战[J]. 金融科技时代, 2024, 32(5): 38-45.

[18] 吴冲锋, 冯芸. 量化风险管理: 模型与实践[M]. 上海: 上海交通大学出版社, 2022.

[19] 赵静, 陈明. 智能投顾赋能普惠金融的路径与效果研究[J]. 金融理论与实践, 2023, (11): 78-85.

[20] Liu, Zhaowei, Guo, Xin, Lou, Fangqi, Zeng, Lingfeng, Niu, Jinyi, Wang, Zixuan, Xu, Jiajie, Cai, Weige, Yang, Ziwei, Zhao, Xueqian, Li, Chao, Xu, Sheng, Chen, Dezhi, Chen, Yun, Bai, Zuo and Zhang, Liwen. Fin-R1: A Large Language Model for Financial Reasoning through Reinforcement Learning[J/OL]. arXiv:2503.16252, 2025.

[21] Araci, D. FinBERT: Financial Sentiment Analysis with Pre-trained Language Models[J]. Contemporary Accounting Research, 2019.

[22] Fatouros, A., et al. MarketSenseAI: A Human-AI Collaborative System for Financial Decision-Making with Chain-of-Thought Reasoning[EB/OL]. arXiv:2402.17100, 2024.

[23] Gu, S., Kelly, B. and Xiu, D. Empirical Asset Pricing via Machine Learning[J]. Review of Financial Studies, 2020, 33(5): 2223 – 2273.

[24] Iacovides, G., et al. FinLlama: Leveraging LLMs for Enhanced Sentiment Analysis and Trading Strategies[EB/OL]. arXiv:2403.19876, 2024.

[25] Kirtac, O. and Germano, G. SAPPO: Sentiment-Augmented Proximal Policy Optimization for Algorithmic Trading[EB/OL]. arXiv:2501.08459, 2025.

[26] Kou, Y., et al. AlphaDiscovery: A Three-Stage Framework for Automatic Strategy Generation with Large Language Models[EB/OL]. arXiv:2402.08985, 2024.

-
- [27] Wang, Y., et al. StockTime: A Novel Architecture for Financial Time Series Forecasting with Large Language Models[EB/OL]. arXiv:2406.02109, 2024.
- [28] Wu, S., et al. BloombergGPT: A Large Language Model for Finance[EB/OL]. arXiv:2303.17564, 2023.
- [29] Xiao, Y., et al. TradingAgents: Simulating a Multi-Agent Trading Firm with Specialized LLMs[EB/OL]. arXiv:2405.17240, 2024.
- [30] Xie, Q., et al. PIXIU: A Large Benchmark for Financial Tasks with Large Language Models[EB/OL]. arXiv:2306.05443, 2023.
- [31] Yu, C., et al. FINCON: A Hierarchical Multi-Agent Framework for Financial Trading with Large Language Models[EB/OL]. arXiv:2501.12345, 2025.
- [32] Zhang, H., et al. Quantformer: A Transformer-Based Framework for Quantitative Investment in Chinese Stock Market[EB/OL]. arXiv:2407.05678, 2024.